




深度學習 Deep Learning

★ **DL Training Tips**

Instructor: 林英嘉 (Ying-Jia Lin)
2025/10/15



[Course GitHub](#)




[Slido # DL1015](#)

Outline

- Model training tips [70 min]
 - EarlyStopping
 - Regularization and AdamW
 - Batch Normalization
 - Dropout
- Code demo [10 min]
- Term Project [50 min]
- Quiz [20 min]




[Recap] 如何訓練模型：資料集




訓練模型的目標

你能收集到的資料



訓練機器學習模型時可能發生的情況

code/w7_plot_overfitting.py




[定義] Overfitting 與 Underfitting

- Underfitting (欠擬合): 模型無法在 training set 取得很低的誤差 (error; loss)
- Overfitting (過擬合): 模型的 training error 與 test error 差異很大
 - test error 通常代表 validation loss
 - 常見模型可以呈現很小的 training error，但 test error 仍大




EarlyStopping

code/w7_plot_overfitting.py



EarlyStopping

code/w7_plot_es.py



Regularization

- 定義：regularization (正則化) 是一種技巧來幫助模型減少 training error 與 test error 的差距 (並非降低 training error)

$$\mathcal{L}_{\text{new}} = \mathcal{L} + \text{regularization_term}$$



Norm (範數)

是具有「長度」概念的函數，其為向量空間內的所有向量的正長度或大小。

假設有一向量 $w = [w_1, w_2, \dots, w_n]$

$$\text{L}^1\text{-Norm} = \sum_{i=1}^n |w_i| = |w_1| + |w_2| + \dots + |w_n|$$

$$\text{L}^2\text{-Norm} = \sqrt{w_1^2 + w_2^2 + \dots + w_n^2}$$



L² Regularization

$w = \{w_1, w_2, \dots, w_n\}$
 λ : 正則項的比例 (0-1之間)

$$\mathcal{L}_{\text{new}} = \mathcal{L} + \lambda \frac{1}{2} \underbrace{\|w\|_2^2}_{w_1^2 + w_2^2 + \dots + w_n^2}$$

代表模型的目標除了要讓 $\mathcal{L}$ 越小越好之外，
還要讓所有的 w 的平方和越小越好



為什麼要增加正則項？

假設我們的模型： $\hat{y} = x_1w_1 + x_2w_2^2 + \dots + x_9w_9^9$

如果沒有正則項，目標函數相當於是為 training set 量身打造

如果 w_9 很大怎麼辦？
正則項 (如 L^2) 能限制
weight 數值大小

假設我們想要學出的模型： $y = x_1w_1 + x_2w_2^2$

非常通用的模型，
可以在 **unseen** 資料上表現好



Gradient Descent with L² Regularization

$$\mathcal{L}_{\text{new}} = \mathcal{L} + \lambda \frac{1}{2} \|w\|_2^2$$

對任意 w_i 進行偏微分：

$$\frac{\partial \mathcal{L}_{\text{new}}}{\partial w_i} = \boxed{\frac{\partial \mathcal{L}}{\partial w_i} + \lambda w_i}$$

梯度下降：

$$w'_i = w_i - \eta \frac{\partial \mathcal{L}_{\text{new}}}{\partial w_i}$$

$$\text{(代入)} = w_i - \eta \left(\frac{\partial \mathcal{L}}{\partial w_i} + \lambda w_i \right)$$

$$\text{(移項)} = \underline{(1 - \eta\lambda)} w_i - \eta \left(\frac{\partial \mathcal{L}}{\partial w_i} \right)$$

每次更新都會倍數遞減
(weight decay)



L¹ Regularization

$w = \{w_1, w_2, \dots, w_n\}$
 λ : 正則項的比例 (0-1之間)

$$\mathcal{L}_{\text{new}} = \mathcal{L} + \lambda \underbrace{\|w\|_1}_{\text{L}^1\text{-Norm}} = \sum_{i=1}^n |w_i| = |w_1| + |w_2| + \dots + |w_n|$$

代表模型的目標除了要讓 $\mathcal{L}$ 越小越好之外，
還要讓所有的 w 的絕對值和越小越好



Gradient Descent with L1 Regularization

$$\mathcal{L}_{\text{new}} = \mathcal{L} + \lambda \|w\|_1$$

梯度下降：

對任意 w_i 進行偏微分：

$$w'_i = w_i - \eta \frac{\partial \mathcal{L}_{\text{new}}}{\partial w_i}$$

$$\frac{\partial \mathcal{L}_{\text{new}}}{\partial w_i} = \frac{\partial \mathcal{L}}{\partial w_i} + \lambda \cdot \text{sign}(w_i)$$

$$\text{(代入)} = w_i - \eta \left(\frac{\partial \mathcal{L}}{\partial w_i} + \lambda \cdot \text{sign}(w_i) \right)$$

每次更新都會扣減
(weight decay)



AdamW will be in Week 7

The paper of AdamW:

Published as a conference paper at ICLR 2019

DECOUPLED WEIGHT DECAY REGULARIZATION

Ilya Loshchilov & Frank Hutter

University of Freiburg

Freiburg, Germany,

{ilya, fh}@cs.uni-freiburg.de

Week7: 過擬合、正規化、模型訓練技巧、期末專案介紹



[Recap] Adam

- Adam: adaptive moment estimation
- 結合了 Momentum、Adagrad 和 RMSProp 的概念



Kingma, Diederik P., and Jimmy Ba. "Adam: A method for stochastic optimization." ICLR 2015. <https://arxiv.org/abs/1412.6980>

[Recap] 如何有效訓練深度學習模型？

Optimizer:

- 對梯度動手腳
 - Momentum
- 自動調整學習率
 - Adagrad
 - RMSprop
 - Adam



[Recap] Adam 流程

- Adam: Momentum、Adagrad 和 RMSProp 的概念

1 計算梯度 $g_t \leftarrow \nabla_w f(w_{t-1})$

2 以移動平均紀錄梯度 g_t (為了對梯度動手腳 -- Momentum)

3 以移動平均紀錄梯度平方 g_t^2 (為了調整學習率 -- Adagrad)

4 更新參數 $w_t \leftarrow w_{t-1} - \eta \hat{m}_t \frac{1}{\sqrt{\hat{v}_t + \epsilon}}$



[實作細節] 把 L^2 Regularization 加到 SGD

總目標： $\mathcal{L}_{\text{new}} = \mathcal{L} + \lambda \frac{1}{2} \|w\|_2^2$

Loshchilov, Ilya, and Frank Hutter. "Decoupled Weight Decay Regularization." International Conference on Learning Representations (2019).

1 計算梯度 $g_t \leftarrow \nabla_w f(w_{t-1}) + \lambda w_{t-1}$ 證明請見 AdamW 論文 Proposition 1 proof

2 更新參數 $w_t \leftarrow w_{t-1} - \eta g_t$

等價於

GD： $w_t = w_{t-1} - \eta \left(\frac{\partial \mathcal{L}}{\partial w_{t-1}} + \lambda w_{t-1} \right)$



[實作細節] 把 L2 Regularization 加到 Adam

在SGD正確，但在Adam是錯的，因為改變1的梯度會影響到梯度紀錄

1 計算梯度 $g_t \leftarrow \nabla_w f(w_{t-1}) + \lambda w_{t-1}$

2 以移動平均紀錄梯度 g_t (為了對梯度動手腳 -- Momentum)

3 以移動平均紀錄梯度平方 g_t^2 (為了調整學習率 -- Adagrad)

4 更新參數 $w_t \leftarrow w_{t-1} - \eta \hat{m}_t \frac{1}{\sqrt{\hat{v}_t + \epsilon}}$



AdamW

分離的

AdamW: Adam with **decoupled** weight decay

- 1 計算梯度 $g_t \leftarrow \nabla_w f(w_{t-1}) + \lambda w_{t-1}$
- 2 以移動平均紀錄梯度 g_t (為了對梯度動手腳 -- Momentum)
- 3 以移動平均紀錄梯度平方 g_t^2 (為了調整學習率 -- Adagrad)
- 4 更新參數 $w_t \leftarrow w_{t-1} - \eta(\hat{m}_t \frac{1}{\sqrt{\hat{v}_t + \epsilon}} + \lambda w_{t-1})$

$$w_t = w_{t-1} - \eta \left(\frac{\partial \mathcal{L}}{\partial w_{t-1}} + \lambda w_{t-1} \right)$$



延伸學習


李宏毅老師影片

<https://youtu.be/xki61j7z-30?si=ofWigNuHKkTdPC4f&t=3463>





Batch Normalization

The whole CNN




Batch Normalization (BatchNorm)

- BatchNorm 對數值進行轉換，使得轉換後的數值的平均值為零、標準差為1
- 類似於統計上的 Z-score standardization



MLP 中的 BatchNorm




$$h'_1 = \frac{h_1 - \mu}{\sigma}$$

$$h'_j = \frac{h_j - \mu}{\sigma}$$



CNN 中的 BatchNorm



(5, 4, 4)


(batch_size, height, width)

μ 計算自這個 batch 的每一個值
 σ 計算自這個 batch 的每一個值



BatchNorm During Test (Inference)

Training



<https://pytorch.org/docs/stable/generated/torch.nn.BatchNorm2d.html>


Moving average

$$\mu_t = \alpha \mu_t + (1 - \alpha) \mu_{t-1}$$

$$\sigma_t = \alpha \sigma_t + (1 - \alpha) \sigma_{t-1}$$

momentum (α) 常見設定為0.1

Inference



$$h'_1 = \frac{h_1 - \mu_t}{\sigma_t}$$

$$h'_j = \frac{h_j - \mu_t}{\sigma_t}$$



[觀察] BatchNorm


- BatchNorm 可以：
 - 減少不同特徵尺度帶來的偏差，避免梯度爆炸或消失
 - 提高模型訓練時的穩定性，加速收斂




Dropout

Dropout

- 每輪訓練時，神經網路每一層的輸入值部份以 p 的機率隨機替換成 0
 - p 是超參數
- 可防止模型過擬合 (over-fitting)，增強模型的泛化能力 (generalization)



Dropout may improve generalization



Srivastava, Nitish, et al. "Dropout: a simple way to prevent neural networks from overfitting." The journal of machine learning research 15.1 (2014): 1929-1958.



model.eval()

- 使用 training 時取得的平均值跟標準差來算 batch normalization
- 關閉 dropout (保留所有的神經元)
 - 測試時已經不需要再更新模型
 - 去除隨機性



Thank you!

Instructor: 林英嘉

 yjlin@cgu.edu.tw

TA: 劉美辰

 m1461014@cgu.edu.tw